Máster Universitario en Investigación en Inteligencia Artificial

Ciencia de Datos y Aprendizaje Automático

Proyecto `Kaggle`

Spaceship Titanic

Juan Carlos Alfaro Jiménez y Fernando Martínez Plumed

{juancarlos.alfaro@uclm.es, fmartinez@dsic.upv.es}

Noviembre 2023

Índice

1. Kaggle **3**
1.1. Registro 3

2. Descripción del problema **3**

3. Exploración y preprocesamiento de datos **4**
3.1. Consejos 4

4. Predicción y evaluación **5**

5. Objetivo **6**

6. Criterios de evaluación **7**

1. Kaggle

Kaggle (www.kaggle.com) es una plataforma donde se reúnen miles de personas con interés o experiencia en el análisis de datos, ofreciendo la posibilidad de competir para resolver requisitos estratégicos que presentan los grandes datos de las empresas a cambio de dinero. Empresas y compañías de todo el mundo exponen sus problemas y sus retos en esta plataforma y la comunidad de científicos de datos compite para crear las mejores soluciones y los mejores modelados teóricos.

En la plataforma se presenta cualquier tipo de problema que pueda encontrarse en los distintos campos del mundo real, tales como servicios financieros, energía, tecnologías de la información, etc.

El enfoque *crowdsourcing* utilizado se debe a la existencia de una cantidad indefinida de posibles soluciones y estrategias que se pueden aplicar a un problema complejo de modelado predictivo donde no es posible saber con antelación la técnica o la estrategia que será más adecuada y más eficaz.

Fundada por el economista australiano Anthony Goldbloom, la inspiración para crear Kaggle proviene en parte de una competición creada por Netflix entre 2006 y 2009. La empresa de alquiler de películas ofrecía un millón de dólares al equipo que fuera capaz de mejorar la precisión de su sistema de recomendación de títulos en un 10 %.

1.1. Registro

El primer paso para el proyecto es registrarse en la plataforma para crear una nueva cuenta de usuario. Una vez se ha realizado el registro, entra en la plataforma y accede al apartado "*Competitions*" donde encontrarás una lista con todas las competiciones, tanto activas como completadas. Busca la competición titulada como "*Spaceship Titanic*" (Figura 1) o accede directamente a través del siguiente enlace: https://www.kaggle.com/competitions/spaceship-titanic.

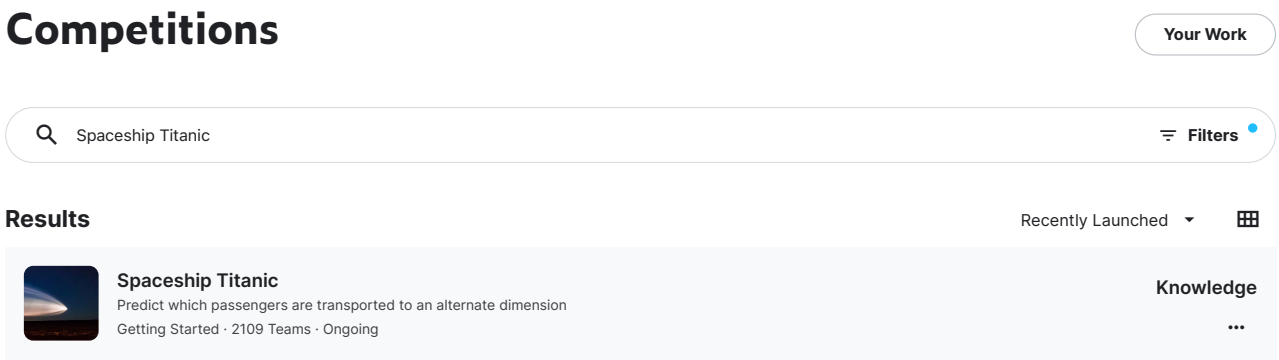

Figura 1: Acceso a la competición *Spaceship Titanic*

Para participar en la competición y descargar los datos del problema deberás aceptar las reglas de la misma.

2. Descripción del problema

Este proyecto busca llevar a cabo un proyecto que permita demostrar las habilidades aprendidas durante el curso. El primer requisito es que el conjunto de datos utilizado posea un número razonable de variables y observaciones para que tengáis que ir más allá de la aplicación de un algoritmo simple de selección de variables para la construcción de un modelo final.

En cuanto al problema a resolver, estamos en 2912 y se ha recibido una transmisión desde cuatro años luz de distancia con malas noticias. La nave espacial *Titanic* emprendió un viaje interestelar para transportar emigrantes de nuestro sistema solar a tres exoplanetas descubiertos recientemente que parecen habitables y orbitan estrellas cercanas. Por desgracia, la nave espacial chocó con una anomalía escondida dentro de una nube de polvo y casi la mitad de los pasajeros fueron transportados a una dimensión alternativa. El problema que se presenta en esta competición es ayudar a las tripulaciones de rescate a recuperar a los pasajeros perdidos, para lo cuál se debe predecir qué pasajeros fueron transportados por la anomalía utilizando los registros recuperados del sistema informático dañado.

Con respecto al conjunto de datos, este está formado por 13000 instancias y 14 variables (incluyendo la variable clase a predecir), las cuáles se centran en la descripción de multitud de aspectos de cada uno de los pasajeros. En general, las variables categóricas hacen referencia al planeta de residencia, destino, etc. Por su parte, las variables numéricas describen la edad, facturación por el servicio de habitaciones, compras, etc.

La tarea del alumno es predecir si los pasajeros fueron transportados a la dimensión alternativa o no. Para comenzar a trabajar, en la pestaña "*Data*" encontraremos los siguientes ficheros: `train.csv`, `test.csv` y `sample_submission.csv`. El conjunto de datos de entrenamiento se encuentra en `train.csv` y consta de 8693 instancias. Por su parte, el conjunto de datos de prueba es `test.csv`, está formado por 4277 instancias y se utilizará para realizar la predicción. Por último, el fichero `sample_submission.csv` proporciona un formato de muestra para el envío de resultados a la plataforma `Kaggle`.

3. Exploración y preprocesamiento de datos

Una vez descargados los datos, es necesario realizar un **extenso análisis descriptivo del conjunto de datos de entrenamiento**, así como un proceso de inspección, limpieza y transformación de datos con el objetivo de resaltar información útil para la fase de modelado. Este análisis nos permitirá controlar la presencia de valores faltantes o la presencia de posibles errores en la fase de introducción de los datos. También nos proporcionará una idea inicial de la forma que tienen los datos (distribución, parámetros de dispersión, etc.), así como las relaciones entre los distintos atributos.

La función principal de esta exploración de los datos es que se utilicen las distintas gráficas, coeficientes, y estadísticas utilizadas como base de cualquier decisión tomada para la generación de los consiguientes modelos de clasificación. Como posibles puntos de partida, se puede analizar los pasajeros transportados en base a la edad o el país de residencia, tal y como se muestra en la Figura 2.

3.1. Consejos

- Recuerda que estamos trabajando sobre el conjunto de datos de entrenamiento y que todas aquellas operaciones de limpieza, transformación, creación de nuevos atributos, etc. que realicemos debemos también aplicarlas sobre el conjunto de datos de prueba. **Para evitar fugas de datos, se debe usar siempre la información del conjunto de datos de entrenamiento. Para ello, se recomienda usar el concepto de *pipeline*.** En los siguientes enlaces se proporciona más información para las principales librerías de aprendizaje automático:
  - `Scikit-learn`: https://scikit-learn.org/stable/modules/compose.html
  - `Caret`: https://recipes.tidymodels.org/articles/recipes.html
  - `Weka`: https://weka.sourceforge.io/doc.dev/weka/filters/MultiFilter.html#MultiFilter--

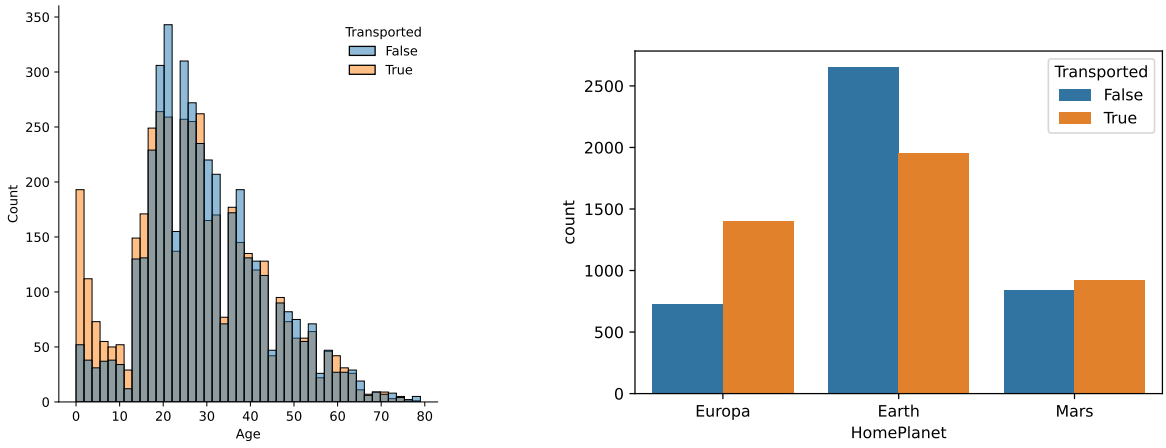

(a) `Age` (b) `HomePlanet`

Figura 2: Distribución de los diferentes atributos condicionados a los valores de la variable clase

- Analiza la existencia de posibles valores anómalos, extremos o inusuales.
- Comprueba si en el conjunto de datos existen valores faltantes. Muchas técnicas **no** pueden procesar observaciones con valores faltantes. Decide qué hacer con los valores faltantes en los atributos (eliminación, transformación, imputación, etc.).
- Explora correlaciones entre atributos numéricos y la variable a predecir.
- Se pueden transformar las variables categóricas en numéricas (p.e., codificación *one-hot*), o numéricas en categóricas (p.e., discretización), aplicando distintas aproximaciones.
- Para obtener un mejor ajuste de los datos, es necesario realizar un análisis más detallado de cada variable categórica.
- Puede ser de utilidad la creación de nuevos atributos a partir de atributos ya existentes que permitan mejorar la descripción de los datos, así como reducir su dimensionalidad.
- También puede ser interesante crear nuevos atributos basados en la interacción de variables altamente correlacionadas.

4. Predicción y evaluación

Una vez hemos realizado nuestro análisis sobre los datos, incluyendo la creación del *pipeline* de preprocesamiento con la limpieza, transformación y generación de nuevas variables interesantes para nuestro estudio, pasamos a la fase del modelado. **De nuevo, se recomienda que el modelo se introduzca, junto con el preprocesamiento, en un *pipeline* de modelado con el objetivo de garantizar que el entrenamiento e inferencia se realiza de una manera metodológica correcta**.

Una vez se ha entrenado el modelo, se puede obtener una evaluación de la predicción en `Kaggle`. Para ello, es necesario subir los resultados obtenidos utilizando el conjunto de datos de prueba a la misma. De esta manera, utilizamos el modelo para realizar la predicción y guardamos el resultado en un fichero `.csv` con el formato que se muestra en la Tabla 1.

Para poder evaluar tu predicción debes volver a la competición en `Kaggle`, pulsar "*Late Submission*", y subir

PassengerId	Transported
0013_01	True
0018_01	False
0019_01	True
0021_01	False
0023_01	False

Cuadro 1: Muestra del fichero `.csv` para su evaluación en `Kaggle`

el archivo `.csv` con la predicción y enviar. Tras unos segundos, y si no hay errores, se obtendrá la tasa de acierto (métrica de rendimiento utilizada en `Kaggle` como evaluación), tal y como se muestra en la Figura 3. En este caso, obtenemos una tasa de acierto de 0.71358 con un análisis discriminante lineal (hiperparámetros por defecto). Los mejores resultados están alrededor de un valor de 0.8, lo cuál nos indica que, para mejorar los resultados, debemos trabajar más tanto en la fase de preprocesado como en la de modelado.

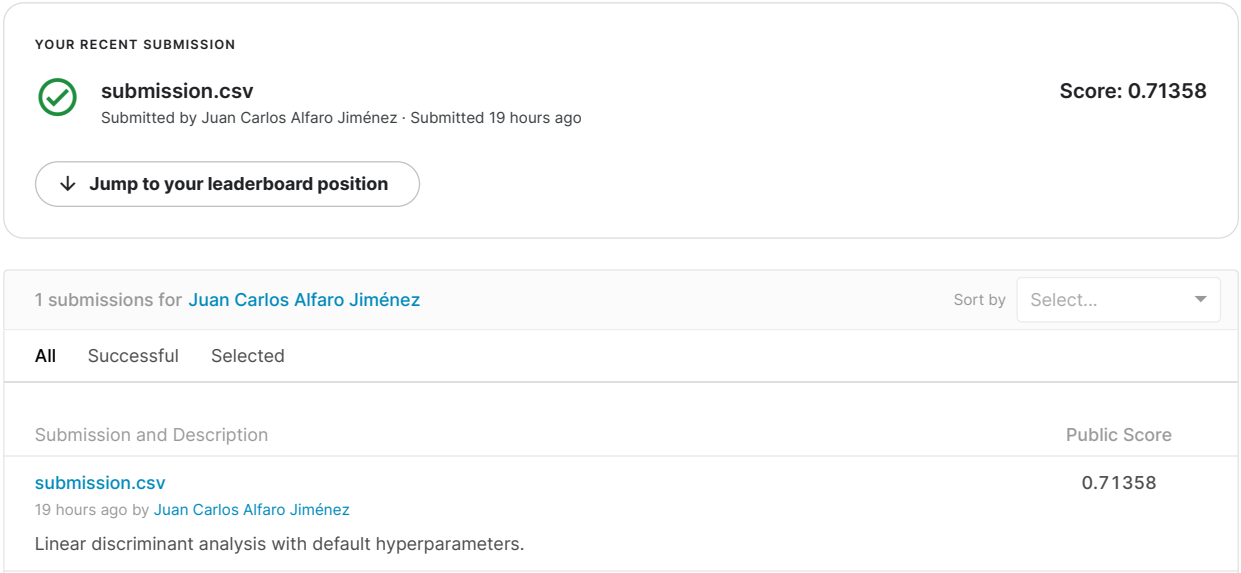

Figura 3: Tasa de acierto obtenida al evaluar el modelo en `Kaggle`

Se debe tener en cuenta que sólo se puede subir un máximo de 5 ficheros de predicciones al día.

En el fichero `notebook.html` adjunto se proporciona un ejemplo ilustrativo de todo este proceso usando un `pipeline` de preprocesamiento y una técnica de modelado sencilla como es un análisis discriminante lineal. Para ello, se ha utilizado la librería `scikit-learn` en `Python`.

5. Objetivo

El objetivo de esta práctica es muy sencillo de explicar: **Construir un modelo de aprendizaje automático que obtenga una estimación lo más precisa posible de la variable `Transported` a partir del resto.**

6. Criterios de evaluación

El proyecto debe realizarse en el lenguaje de programación de preferencia. Como entregable de este proyecto se realizará una memoria de **máximo 10 páginas** describiendo el proceso realizado en cada una de las fases de proyecto. Puede servir como guía (no exhaustiva):

- Introducción y descripción del problema
- Comprensión y preprocesado de datos:
  - Exploración y visualización de datos
  - Limpieza (valores faltantes, extremos, etc.)
  - Procesado de variables numéricas (estudios de correlaciones, discretizaciones u otras transformaciones, etc.)
  - Procesado de variables categóricas (asociaciones y dependencias, numerizaciones, etc.)
  - Construcción, formateo y estandarización de variables (creación de nuevas variables, normalizaciones, etc.)
  - Selección horizontal o vertical (selecciones de atributos basadas en filtros, modelos, correlaciones, pesos, etc.)
- Modelado (técnicas de aprendizaje utilizadas, construcción, comparativas, hiperparámetros, etc.)
- Evaluación (criterio de evaluación, resultados, comparativas, etc.)

Finalmente, se deberá incluir también:

- Conclusiones (análisis de resultados, lecciones aprendidas tras la realización del proyecto, etc.)
- Resultado en `Kaggle` (usuario y valor de la métrica de rendimieto obtenida mediante una captura de pantalla)

Se valorará muy positivamente la claridad de la memoria y la capacidad de síntesis. Aunque se hayan probado muchas cosas, los alumnos deben decidirse por un modelo únicamente, que es el que se evaluará en la plataforma `Kaggle` (generalmente el que hayan conseguido colocar más arriba, pero podría ser otro de su elección). **Es fundamental razonar y justificar todas las decisiones tomadas por el alumno en cada una de las fases**. Se deberá especificar claramente el usuario utilizado y el resultado obtenido para su comprobación mediante una captura de pantalla.

Por otra parte, además de la memoria, **se evaluará al alumno por medio de una entrevista por videoconferencia acerca del desarrollo del proyecto**. En la misma, se espera que se describirá brevemente el desarrollo realizado y deberá responder acerca de cualquier particularidad del proyecto que se considere relevante. Una vez finalizada la fecha de entrega de la memoria, el profesorado encargado de la evaluación del proyecto final se pondrá en contacto para concertar una cita.

Se deberán respetar todas las normas de `Kaggle` y no usar otros usuarios adicionales al de la práctica para conseguir sobrepasar el límite de subidas por día que permite la plataforma.

La comunidad de usuarios de `Kaggle` proporciona una gran ayuda para la resolución de los distintos proyectos por medio de sus foros y libretas. Se recomienda la utilización de los mismos tanto para comenzar con el proyecto

como para resolver dudas o coger ideas. **Cualquier pieza de código utilizada que provenga de cualquiera de estas fuentes debe ser citada en la evaluación**.

Para la nota final se valorará que:

- La predicción del modelo haya sido evaluada en `Kaggle`. Cuanto mayor sea la tasa de acierto, mejor será la valoración por este concepto.
- Se haya trabajado en el preprocesado (análisis, limpieza y transformación) de los datos y su comprensión.
- Se haya trabajado en el modelado intentando mejorar el resultado.
- Se haya realizado una validación correcta.
- Se responda adecuadamente a las cuestiones planteadas y que de las respuestas no haya dudas de que se ha realizado la práctica y que se sabe manejar mínimamente las herramientas que se hayan utilizado.